

---

TP N° 1

---

**EXERCICE 1.** Jeux de données *wine*.

- 1) Ouvrir (avec R ou Python) les deux jeux de données proposés (*white* et *red*).
- 2) Implémenter l'algorithme de gradient en ligne avec des prédicteurs linéaires  $f_\theta(x) = \langle \theta, x \rangle$  et la fonction de perte absolue  $\ell(y', y) = |y - y'|$ . Tester cet algorithme sur le jeu de données *white* :
  - comparer plusieurs versions, avec un pas  $\eta_t$  fixe ou dépendant du temps ;
  - comparer cette méthode de prédiction à la méthode élémentaire qui prédit  $\hat{y}_t = 5$  pour tout  $t$  ;
  - proposer des représentations graphiques.
- 3) Tester maintenant cet algorithme sur le jeu de données *red* :
  - comparer à la méthode élémentaire qui prédit  $\hat{y}_t = 5$  pour tout  $t$  ;
  - comparer à un prédicteur statique fabriqué uniquement sur le jeu de données *white* ;
  - comparer l'effet de considérer *white* et *red* comme deux problèmes différents, ou comme un seul problème (sans ré-initialiser le paramètre au début du jeu de données *red*).

**EXERCICE 2.** Frank Rosenblatt a proposé en 1956 un algorithme appelé **Perceptron** pour la classification linéaire dans le cas réalisable. Cet algorithme est considéré comme le premier réseau de neurones (à une seule couche).



On suppose que l'on a une suite  $(x_t, y_t)_{t \geq 1}$  avec les propriétés suivantes. Tout d'abord,  $x_t \in \mathcal{B}_d(0, R) = \{x \in \mathcal{R}^d : \|x\| \leq R\}$ . D'autre part, on pose pour  $w \in \mathbb{R}^d$  et  $b \in \mathbb{R}$ , pour tout  $x$ ,  $f_{w,b}(x) = w^T x + b$ . Enfin, on suppose qu'il existe  $(\tilde{w}, \tilde{b})$  tels que pour tout  $t$ ,  $y_t = \text{sgn}[f_{\tilde{w}, \tilde{b}}(x_t)]$ . Quitte à renormaliser, on suppose que  $\|\tilde{w}\| = 1$ . En fait, on suppose même qu'il existe  $\gamma > 0$  tel que

$$y_t f_{\tilde{w}, \tilde{b}}(x_t) \geq \gamma$$

pour tout  $t$ . On dit qu'on peut séparer les  $+1$  et les  $-1$  avec une marge  $\gamma$ . L'algorithme est alors défini par :

init :  $w_0 = 0, b_0 = 0$ .

prev.  $t$  :  $\hat{y}_t = \text{sgn}[f_{w_t, b_t}(x_t)]$ .

update :  $w_{t+1} = w_t + y_t x_t$  et  $b_{t+1} = b_t + y_t R^2$  si  $y_t \hat{y}_t \leq 0$ ;  $w_{t+1} = w_t$  et  $b_{t+1} = b_t$  sinon.

Pour alléger les notations, il est commode de poser  $X_t = (x_t, R)$ ,  $W_t = (w_t, b/R)$  et  $\tilde{W} = (\tilde{w}, \tilde{b}/R)$ .

- 1) Pourquoi est-il raisonnable de supposer  $\tilde{b} \leq R$ ?
- 2) Par récurrence, démontrer que  $\forall t \in \mathbb{N}$ , on a

$$W_{t+1}^T \tilde{W} \geq \gamma \sum_{i=1}^t \mathbf{1}(\hat{y}_i \neq y_i).$$

- 3) Démontrer, également par récurrence, que pour tout  $t$ ,

$$\|W_{t+1}\|^2 \leq 2R^2 \sum_{i=1}^t \mathbf{1}(\hat{y}_i \neq y_i).$$

- 4) En déduire le Théorème de Novikoff :

$$\forall t \in \mathbb{N}, \quad \sum_{i=1}^t \mathbf{1}(\hat{y}_i \neq y_i) \leq \left( \frac{2R}{\gamma} \right)^2.$$

**EXERCICE 3.** On suppose données une famille dénombrable de fonctions  $(f_n, n \in \mathbb{N}^*)$  avec  $f_i : \mathcal{X} \rightarrow \{0, +1\}$  et une suite d'observations  $(x_t, y_t)_{t \geq 1}$  vérifiant  $x_t \in \mathcal{X}$  et  $\exists i_0, \forall t, y_t = f_{i_0}(x_t)$ . Il s'agit en gros du modèle d'apprentissage de Gold (celui-ci se restreignant au cas de fonctions  $f_n$  récursives totales).

- 1) On définit une adaptation de l'algorithme **Consistent** à ce contexte :  $V(1) = \mathbb{N}^*$ , et à chaque étape  $t$ ,  $i(t) = \min V(t)$ ,  $\hat{y}_t = f_{i(t)}(x_t)$  et  $V(t+1) = \{i \in V(t) : f_i(x_t) = y_t\}$ . Vérifier (c'est assez immédiat) que

$$\forall T \in \mathbb{N} : \quad \sum_{t=1}^T \mathbf{1}(y_t \neq \hat{y}_t) \leq i_0 - 1.$$

- 2) On définit maintenant une version bayésienne de l'algorithme **Halving**, que l'on notera **Bayesian Halving** : on fixe une loi de probabilité  $\pi$  sur  $\mathbb{N}^*$  et on pose  $V_1 = \mathbb{N}^*$ . A chaque étape  $t$ , on pose

$$\hat{y}_t = \begin{cases} 1 & \text{si } \frac{\sum_{i \in V_t} \pi(i) f_i(x_t)}{\pi(V_t)} \geq \frac{1}{2} \\ 0 & \text{sinon,} \end{cases}$$

puis  $V_{t+1} = \{i \in V_t : f_i(x_t) = y_t\}$ .

- (a) Démontrer que

$$\forall T \in \mathbb{N} : \quad \sum_{t=1}^T \mathbf{1}(y_t \neq \hat{y}_t) \leq \log_2 \left( \frac{1}{\pi(i_0)} \right).$$

- (b) En choisissant  $\pi$  de façon adéquate, démontrer le Théorème de Barzdin et Freivalds qui dit qu'il existe deux constantes  $a > 0, b > 0$  (à préciser) et une stratégie de prédictions vérifiant

$$\forall T \in \mathbb{N} : \quad \sum_{t=1}^T \mathbf{1}(y_t \neq \hat{y}_t) \leq a + b \log_2(i_0)$$

(la stratégie utilisée par ces deux auteurs était légèrement différente, mais reposait aussi sur l'idée de **Halving**).